

Faster R-CNN ve YOLOv11 Kullanarak Ultrason Görüntülerinde Derin Öğrenme Tabanlı Böbrek Taşı Tespiti

Hakan Doğan

Yapay Zeka Mühendisliği Bölümü
TOBB Ekonomi ve Teknoloji Üniversitesi
Ankara, Türkiye
hakandogan@etu.edu.tr

Özet—Bu çalışma, ultrason görüntülerinde böbrek taşı tespiti için derin öğrenme tabanlı bir yaklaşım sunmaktadır. İki nesne tespiti modeli, Faster R-CNN ve YOLOv11, uygulanmış ve değerlendirilmiştir. Çalışma, düşük kontrastlı ve gürültülü ultrason verilerinin tıbbi görüntü analizinde kullanılabilirliğini vurgulayarak, BT (Bilgisayarlı Tomografi) tabanlı yöntemlere kıyasla daha uygun maliyetli ve erişilebilir bir alternatif sunmaktadır. Deneysel sonuçlar umut verici bir performans sergilemekte olup, klinik uygulamalar için potansiyel taşımaktadır.

Anahtar Kelimeler—böbrek taşı, ultrason, nesne tespiti, Faster R-CNN, YOLOv11, derin öğrenme

I. GİRİŞ

Böbrek taşı hastalığı (nephrolithiasis), dünya genelinde milyonlarca insanı etkileyen yaygın bir ürolojik rahatsızlıktır. Bu hastalık, böbreklerde sert mineral ve tuz birikintilerinin oluşmasıyla karakterize edilir ve tedavi edilmediği takdirde şiddetli ağrıya, enfeksiyona veya böbrek hasarına neden olabilir. Erken teşhis, komplikasyonların azaltılmasında, zamanında tedavi planlamasında ve hasta sonuçlarının iyileştirilmesinde hayati bir rol oynamaktadır.

Bilgisayarlı Tomografi (BT), yüksek mekânsal çözünürlüğü ve detaylı anatomik görselleştirme kabiliyeti sayesinde böbrek taşı tespiti için altın standart olarak kabul edilmektedir. Ancak, BT taramaları pahalıdır, düşük kaynaklı ortamlarda erişilebilirliği sınırlıdır ve iyonlaştırıcı radyasyon içerdiğinden sık kullanıma veya tarama amaçlı kullanımına uygun değildir.

Öte yandan, ultrason (USG), daha güvenli, daha uygun maliyetli ve taşınabilir bir görüntüleme alternatifi sunmaktadır. Acil servislerde ve ayakta tedavi kliniklerinde sıkça kullanılmaktadır. Bununla birlikte, USG görüntülerinin otomatik analizinde çeşitli zorluklar mevcuttur. Bunlar arasında düşük kontrast, lekeli gürültü (speckle noise), operatöre bağımlılık ve cihazlar ile hastalar arasında değişken görüntü kalitesi yer almaktadır.

Bu çalışma, söz konusu zorlukları aşmak amacıyla, ultrason görüntülerinde böbrek taşı tespiti doğruluğunu ve otomasyonunu artırmak için derin öğrenmeye dayalı nesne tespiti modellerinden faydalanmaktadır. Çalışmada özellikle iki modern model incelenmiştir: yüksek doğruluk ve detaylı sınırlayıcı kutu (bounding box) tahminleri ile bilinen Faster Region-based

Convolutional Neural Network (Faster R-CNN) ve gerçek zamanlı tespit kapasitesi ve hızıyla öne çıkan You Only Look Once versiyon 11 (YOLOv11).

Amaç, USG görüntülerinde böbrek taşları ile normal böbrek yapıları olmak üzere iki temel yapıyı otomatik olarak ayırt edebilen uçtan uca bir sistem geliştirmektir. Bu sistem, Roboflow Universe platformundan alınan etiketli veri setlerini kullanmakta ve önceden eğitilmiş modelleri, ultrason verisinin özel karakteristiklerine uyarlamak için transfer öğrenme yöntemini benimsemektedir. Yoğun eğitim, değerlendirme ve performans görselleştirme süreçleriyle hangi modelin doğruluk ve hız açısından en iyi dengeyi sağladığı araştırılmıştır.

Ultrason tabanlı nesne tespiti alanında az çalışılmış bir konuyu hedef alan bu araştırma, böbrek taşı tanısı için yapay zekâ destekli araçlara yönelik önemli bir katkı sağlamaktadır. Nihai olarak bu çalışmanın çıktıları, klinik karar verme süreçlerini desteklemeyi, radyologların iş yükünü azaltmayı ve acil tıp ile üroloji alanlarında gerçek zamanlı tanı uygulamalarının temellerini atmaya amaçlamaktadır.

Not: Tüm model uygulamaları Python dilinde gerçekleştirilmiş olup, Faster R-CNN için PyTorch, YOLOv11 için ise Ultralytics kullanılmıştır. Eğitim ve deneyler, GPU hızlandırılmış Google Colab ortamında yürütülmüştür. Roboflow'daki veri çoğaltma ve etiketleme araçlarından faydalanılmıştır.

II. KOD GENEL BAKIŞI

Böbrek taşı tespit sistemi uygulaması, Faster R-CNN ve YOLOv11 modellerine karşılık gelen iki ayrı boru hattından (pipeline) oluşmaktadır. Her bir boru hattı; veri yükleme, ön işleme, model tanımı, eğitim, değerlendirme ve çıkarım (inference) modüllerini içermektedir.

A. Faster R-CNN Boru Hattı

Faster R-CNN modeli, PyTorch çatısı kullanılarak geliştirilmiş ve önceden eğitilmiş ResNet50 omurgası ile Özellik Piramit Ağı (FPN) temel alınmıştır. Boru hattı şu temel bileşenlerden oluşmaktadır:

- **Özel Veri Kümesi Sınıfı:** Görselleri ve etiketlemeleri okumak için bir PyTorch Dataset sınıfı tanımlanmıştır.

Bu sınıf, sınırlayıcı kutu koordinatlarını, sınıf etiketlerini işler ve dönüşümler uygular.

- **Dönüşümler:** Girdi görüntüleri normalize edilip yeniden boyutlandırılmıştır. Veri artırımı yalnızca eğitim sırasında uygulanmıştır.
- **Model Değişikliği:** Önceden eğitilmiş Faster R-CNN modeli, çıktı sınıfı sayısına (arka plan, böbrek taşı, normal böbrek) uyacak şekilde yeniden yapılandırılmıştır.
- **Eğitim Döngüsü:** Eğitim döngüsü, kayıp fonksiyonu geri yayılımı (backpropagation), optimize edici güncellemeleri ve her epoch sonrası değerlendirme işlemlerini içermektedir. Öğrenme oranı 0.005, momentum ise 0.9 olarak belirlenmiştir.
- **Değerlendirme:** Özel değerlendirme fonksiyonları; sınıflandırma, kutu regresyonu ve RPN kayıplarını hesaplamakta ve isteğe bağlı olarak tespit edilen sınırlayıcı kutuların görselleştirmelerini üretmektedir.
- **Model Kaydetme:** Eğitilmiş ağırlıklar '.pth' formatında gelecekteki çıkarımlar için kaydedilmiştir.

B. YOLOv11 Boru Hattı

YOLOv11 uygulaması, Ultralytics API'si ve komut satırı arayüzü kullanılarak gerçekleştirilmiş olup, yapılandırma dosyaları aracılığıyla hızlı eğitim ve değerlendirme imkânı sunmaktadır.

- **Önceden Eğitilmiş Model Başlatımı:** Model, 'yolo11m.pt' ağırlıkları kullanılarak başlatılmıştır.
- **Veri Yapılandırması:** Bir YAML dosyası, eğitim, doğrulama ve test veri yolları, sınıf isimleri ve görüntü boyutunu belirtmektedir.
- **Eğitim:** Ana deneyler 640x640 piksellik giriş boyutu ve AdamW optimize edici kullanılarak 20 epoch boyunca gerçekleştirilmiştir. Ayrıca, ara raporda sunulan sınıf sadeleştirme analizi için 100 epoch'luk genişletilmiş bir eğitim yapılmıştır. Projenin son aşamasında, 60 epoch boyunca rafine edilmiş bir YOLOv11 modeli eğitilerek gerçek dünya koşullarında performans artırılmıştır. Her eğitim çalışmasında en iyi performansı gösteren model 'best.pt' olarak kaydedilmiştir.
- **Doğrulama:** Model, Intersection over Union (IoU) eşik değeri 0.5'teki ortalama doğruluk (mAP50), hassasiyet (precision) ve geri çağırma (recall) gibi metrikleri değerlendirir. Bu metrikler her epoch sonunda kaydedilmiştir.
- **Çıkarım (Inference):** Eğitim sonrası, yeni ultrason görüntüleri üzerinde çıkarım yapılmış ve tespit edilen sınırlayıcı kutular yerleşik çizim fonksiyonları kullanılarak görselleştirilmiştir.

III. VERİ KÜMESİ

A. Kaynak ve İçerik

Bu çalışmada kullanılan veri kümesi, Roboflow Universe platformundan temin edilmiştir ve *Kidney Stone Ultrasound (ECKKD)* [9] başlığını taşımaktadır. Veri kümesi, iki ana nesne sınıfı için etiketlenmiş ultrason görüntülerini içermektedir:

- **Böbrek Taşı (sınıf 1):** 15.107 adet sınırlayıcı kutu

- **Normal Böbrek (sınıf 2):** 2.280 adet sınırlayıcı kutu

Toplamda 5.431 görüntüden oluşan veri kümesinde, görüntülerin ortalama çözünürlüğü 640x640 pikseldir ve ortalama görüntü boyutu yaklaşık 0.41 megapiksel civarındadır. Her görüntüde ortalama 3.2 etiket bulunmaktadır. Etiket yoğunluğu haritası, nesnelerin çoğunlukla görüntülerin merkezi bölgelerinde kümelendiğini göstermektedir.




Fig. 1. Sınıf başına sınırlayıcı kutu (bounding box) sayıları.

B. Veri Artırımı

Modelin dayanıklılığını artırmak ve sınıf dengesizliğini azaltmak amacıyla aşağıdaki artırma teknikleri uygulanmıştır:

- Yatay çevirme
- Dikey çevirme

Her bir orijinal görüntüden üç yeni varyasyon üretilmiştir; böylece farklı tarama açıları ve anatomik yönelimler simüle edilmiştir. Bu artırma teknikleri yalnızca eğitim setine uygulanmıştır; böylece veri sızıntısı önlenmiş ve değerlendirme sonuçlarının geçerliliği korunmuştur.

Bu işlem sonucunda, orijinalde 5.431 olan görüntü sayısı 11.155'e çıkarılmıştır. Böylelikle modelin daha önce görmediği örnekleri genelleme yetisi artırılmış ve sınırlı/ dengesiz verilerde aşırı öğrenme (overfitting) riski azaltılmıştır.

C. Veri Bölünmesi ve Dağılımı

Veri kümesi eğitim, doğrulama ve test alt kümelerine şu şekilde bölünmüştür:

- Eğitim Seti: 10.069 görüntü (yüzde 90)
- Doğrulama Seti: 544 görüntü (yüzde 5)
- Test Seti: 542 görüntü (yüzde 5)

Sınıf dağılımı dengesizdir; böbrek taşı sınıfına ait örnekler açık ara fazladır.

D. Veri Kalitesiyle İlgili Zorluklar

Bu veri kümesiyle çalışırken karşılaşılan başlıca zorluklardan biri, ultrason görüntülemeye özgü düşük görüntü kalitesidir. BT veya MR görüntülemeye kıyasla, ultrason görüntülerinin dezavantajları şunlardır:

- Düşük kontrast ve çözünürlük

- Lekeli (speckle) gürültü
- Cihazlar arası değişken görüntüleme koşulları
- Uzman olmayan kişiler tarafından yapılan etiketlemelere bağlı olası hatalar

Bu faktörler, modellerin genelleme yetisini düşürebilir ve sağlam ön işleme adımları olmaksızın etkili sonuçlar elde etmeyi zorlaştırır.

E. Ön İşleme Teknikleri

Ultrason görüntülerinin düşük kontrastı, speckle (lekeli) gürültü içeriği ve görüntüleme cihazları arasındaki kalite farklılıkları, derin öğrenme tabanlı modellerin doğrudan etkili çalışmasını zorlaştırmaktadır. Bu nedenle, eğitim verisi üzerine çeşitli ön işleme adımları uygulanarak modelin genelleme yeteneği ve öğrenme başarımı artırılmaya çalışılmıştır. Bu adımlar temel ve deneysel olarak iki grupta ele alınmıştır.

Temel Ön İşleme Adımları

- **Gri Tonlamaya Dönüştürme:** Tüm görüntüler gri tonlamaya çevrilerek kanal sayısı sabitlenmiş ve giriş formatı standardize edilmiştir. Bu işlem, farklı veri kaynaklarından gelen görüntülerin tek tip formatta modele sunulmasını sağlamıştır.
- **Yeniden Boyutlandırma:** Tüm görüntüler 640×640 piksel boyutuna yeniden ölçeklendirilmiştir. Bu adım, hem Faster R-CNN hem de YOLOv11 modelleriyle uyumlu sabit giriş boyutu gereksinimini karşılamış, hem de GPU bellek kullanımı açısından verimlilik sağlamıştır.
- **Format Dönüşümü:** Etiketler, kullanılan modele uygun formatlara dönüştürülmüştür. YOLOv11 için YOLO biçimi (merkez koordinatları ve kutu boyutları), Faster R-CNN için ise Pascal VOC biçimi (piksel tabanlı sınırlayıcı kutular) kullanılmıştır.

Deneysel Ön İşleme Stratejileri

Bazı deneysel çalışmalarda, temel boru hattına ek olarak aşağıdaki ön işleme yöntemleri test edilmiştir. Bu yöntemlerin model başarımı üzerindeki etkisi, Bölüm V kapsamında karşılaştırmalı olarak değerlendirilmiştir.

- **Temel Görüntü Geliştirme:** Medyan bulanıklaştırma ($k = 5$) ve CLAHE (Sınırlı Kontrast Uyumlu Histogram Eşitleme, parça boyutu = 8×8) birlikte uygulanmıştır. Bu işlem, speckle gürültüsünü yumuşatırken lokal kontrastı artırmayı hedeflemiştir. Ancak yapılan deneylerde, bu stratejinin model doğruluğu üzerinde yalnızca sınırlı ve istatistiksel olarak önemsiz etkileri olduğu gözlemlenmiştir.
- **Gelişmiş Gürültü Azaltma (BM3D + FFT):** Speckle gürültüsünü daha ileri düzeyde bastırmak amacıyla, Dabov ve arkadaşları tarafından önerilen BM3D algoritması [10] uygulanmıştır. Bu yöntem, benzer yama bloklarını shape-adaptive PCA kullanarak üç boyutlu uzayda filtrelemekte ve yüksek frekanslı rastgele gürültüyü azaltmaktadır. BM3D işleminden sonra, görüntülerin hızlı Fourier dönüşümü (FFT) alınmış ve dairesel bir düşük geçişli maske uygulanarak frekans uzayında

fırçamsı eşikleme gerçekleştirilmiştir. Ancak deneysel bulgular, bu yöntemin sınırlayıcı kutu kalitesini kısmen artırmasına rağmen, genel mAP ve geri çağırma gibi metrikler üzerinde belirgin bir iyileştirme sağlamadığını göstermiştir.

IV. MODEL GELİŞTİRME

Bu çalışmada model geliştirme süreci, iki farklı derin öğrenme tabanlı nesne tespiti mimarisinin eğitimi ve değerlendirilmesine odaklanmaktadır: Faster R-CNN ve YOLOv11. Her iki model de düşük çözünürlüklü ve gürültülü ultrason görüntüleri üzerinde etkili şekilde çalışacak şekilde uyarlanmış, böbrek taşlarını tespit etmek ve normal böbrek yapılarından ayırt etmek üzere eğitilmiştir.

A. Faster R-CNN ile Nesne Tespiti

Faster R-CNN, iki aşamalı bir nesne tespit modelidir. İlk aşamada, Bölge Öneri Ağı (Region Proposal Network - RPN), nesne içerebilecek aday bölgeleri üretir. İkinci aşamada ise bu bölgeler sınıflandırılır ve konumları hassas şekilde ayarlanır.

Bu projede ultrason görüntülerinde böbrek taşı tespiti için iki farklı eğitim yaklaşımı uygulanmıştır:

1. İlk Yaklaşım: İlk yaklaşımda, PyTorch'un torchvision kütüphanesinden alınan önceden eğitilmiş `fasterrcnn_resnet50_fpn` modeli transfer öğrenme ile ince ayar yapılarak eğitilmiştir. Kullanılan eğitim parametreleri şunlardır:

- Epoch sayısı: 10
- Öğrenme oranı: 0.005
- Momentum: 0.9
- Optimizasyon: SGD

Kayıp fonksiyonları; sınıflandırma kaybı, sınırlayıcı kutu regresyon kaybı ve RPN ile ilgili kayıpları içermektedir; ancak performans metrikleri ve eğitim grafikleri, istenilen düzeyde sonuç elde edilemediğini göstermiştir (Şekil 2).




Fig. 2. Faster R-CNN modelinin ilk deneyine ait F1 skoru, Precision, Recall ve Precision-Recall eğrileri. Modelin eşik değerlerine göre gösterdiği değişken performans görülmektedir.

2. Geliştirilmiş Yaklaşım: İlk yaklaşımın ardından, daha gelişmiş bir açık kaynak deposu klonlanmış ve eğitim süreci ile yapılandırmalar iyileştirilmiştir. Bu gelişmiş yapılandırmada:

- Model konfigürasyonları ve eğitim betikleri güncel versiyonlarla değiştirilmiştir.
- Eğitim süresince sınıflandırma, kutu regresyonu, RPN kayıpları gibi çeşitli kayıp bileşenleri detaylı şekilde takip edilmiştir.

Performans metrikleri olarak mAP, hassasiyet, geri çağırma ve F1-skoru kullanılmıştır. Eğitim süreci Şekil 3'te özetlenmiştir.




Fig. 3. Geliştirilmiş Faster R-CNN eğitiminde mAP50, sınıflandırma kaybı ve kutu regresyonu kaybı metrikleri.

Modelin daha detaylı değerlendirme metrikleri Şekil 4'te özetlenmiştir. Eşik değerine göre Precision, Recall ve F1 skorları ile Precision-Recall eğrisi birlikte gösterilerek modelin genel davranışı görselleştirilmiştir.




Fig. 4. Yukarıda: Güven eşiğine göre Precision, Recall ve F1 Skoru değişimi. Aşağıda: Precision-Recall eğrisi

Sonuçlar ve Değerlendirme: Her iki eğitim yaklaşımı da ultrason görüntülerinden böbrek taşlarının tespiti üzerine odaklanmıştır. Performans, mAP, hassasiyet, geri çağırma ve F1-skoru ile takip edilmiştir. Geliştirilmiş eğitim yaklaşımı ile ilk deneye kıyasla model eğitimi daha iyi kontrol edilmiş ve gözlemlenmiştir.

B. YOLOv11

YOLOv11, Ultralytics tarafından geliştirilen tek aşamalı bir nesne tespiti modelidir. Görüntüyü tek bir ileri geçişte işler ve

sınırlayıcı kutular ile sınıf olasılıklarını doğrudan tahmin eder. Hızı ve gerçek zamanlı performansı ile bilinir.

YOLOv11 uygulaması, `yolo11m.pt` önceden eğitilmiş ağırlıkları ile başlatılır. Model, bir YAML yapılandırma dosyası aracılığıyla veri yolları, görüntü boyutu (640x640) ve sınıf isimleri belirtilerek ince ayar yapılır.

- Epoch sayısı: 60 (varsayılan), deneylerde 20 ve 100 epoch kullanılmıştır.
- Optimizasyon: AdamW
- Girdi Boyutu: 640x640
- Çıktı: `best.pt` olarak kaydedilen en iyi model ağırlıkları

1) *Yerleşik Ön İşleme Boru Hattı:* Ultralytics çerçevesi aracılığıyla YOLOv11'in önemli avantajlarından biri, otomatik ve optimize edilmiş ön işleme boru hattıdır. Eğitim ve çıkarım sürecinde aşağıdaki işlemler otomatik olarak uygulanmaktadır:

- **Letterbox Yeniden Boyutlandırma:** Hedef çözünürlüğe (640x640) yeniden boyutlandırırken oran korunarak kenarlara dolgu eklenir.
- **Mozaik Artırımı:** Dört farklı görüntü tek bir karede birleştirilerek modelin farklı yerleşim düzenlerine maruz kalması sağlanır.
- **HSV Renk Uzayı Dönüşümü:** (RGB görüntüler için geçerli) Renk tonunda, doygunlukta ve parlaklıkta rastgele değişiklikler uygulanır.
- **Çevirme ve Ölçekleme:** Yatay/dikey çevirme ve rastgele yeniden ölçekleme, çeşitli çekim senaryolarını simüle eder.

Tüm bu adımlar, YOLOv11'in `train.py` betiği tarafından otomatik olarak gerçekleştirilir ve modeli manuel müdahale olmadan genelleştirilebilir hale getirir.

Model performansı; mAP@0.5, sınıf bazlı hassasiyet ve geri çağırma metrikleri ile değerlendirilmiş, ayrıca test görüntülerinde sınırlayıcı kutu tahminleri görsel olarak doğrulanmıştır. Model şu performansı göstermiştir:

- Böbrek taşı sınıfı için mAP50: %62–63
- Normal böbrek sınıfı için mAP50: maksimum %98

Modelin eğitim süreci boyunca elde edilen temel kayıp fonksiyonları ve doğruluk metrikleri Şekil 5'te sunulmuştur. Eğitim ve doğrulama evrelerinde gözlemlenen kutu (box), sınıf (class) ve dağılım (DFL) kayıplarında istikrarlı bir azalma yaşanırken; hassasiyet (precision), geri çağırma (recall), mAP@0.5 ve mAP@0.5:0.95 değerlerinde sürekli bir artış gözlemlenmiştir. Bu sonuçlar, modelin zamanla daha kararlı ve doğru tahminlerde bulunma yeteneğini kazandığını göstermektedir.

Ek olarak, Şekil 6'te verilen normalize edilmiş karışıklık matrisi, modelin her sınıf için tahmin başarımını detaylı şekilde ortaya koymaktadır. Model, özellikle *normal böbrek* sınıfında yüksek doğrulukla tahminler yaparken, *böbrek taşı* sınıfı için de belirgin bir başarı elde etmiştir. Bu durum, sınıf dengesizliğine rağmen modelin hem majör hem de minör sınıflarda genelleme yapabildiğini göstermektedir.




Fig. 5. YOLOv11 modelinin eğitim sürecindeki kayıp fonksiyonları (üstte: eğitim, altta: doğrulama) ve doğruluk metriklerinin epoch bazında değişimi.




Fig. 6. YOLOv11 modeline ait normalize edilmiş karışıklık matrisi. Her hücre, ilgili sınıflar arasındaki tahmin oranlarını göstermektedir.

C. Model Karşılaştırması ve Dağıtım Hususları

Tablo I, YOLOv11m ve Faster R-CNN modellerini temel performans ve kaynak kullanım metriklerine göre kapsamlı bir şekilde karşılaştırmaktadır.

YOLOv11m, daha az parametreye sahip olmasına (20M vs. 42M) ve daha küçük model boyutuna rağmen, neredeyse tüm metriklerde Faster R-CNN'den daha iyi performans göstermiştir—özellikle mAP@0.5 (ortalama 0.789 vs. 0.684) ve normal böbrek sınıfı için (0.979 vs. 0.450). Ayrıca, çok daha hızlı çıkarım süresi sayesinde gerçek zamanlı uygulamalara daha uygundur.

Faster R-CNN, ilk 5 epoch sonunda makul bir performans sergilemiş olsa da, eğitim süresi 20 epoch'a uzatıldığında performans özellikle böbrek taşı sınıfında düşmüştür. Bu durum, modelin uzun süreli eğitimlerde aşırı öğrenmeye meyilli olduğunu ve ek düzenleme (regularization) veya veri artırımı olmadan performansın azalabileceğini göstermektedir. Mimari olarak teorik potansiyeli olsa da, mevcut konfigürasyonunda zorlu sınıflarda performans artışı sağlayamamıştır.

Faster R-CNN'in elde ettiği yüksek mAP@0.5 değeri büyük ölçüde kolay tespit edilebilen *normal böbrek* sınıfındaki yüksek doğruluktan kaynaklanmaktadır. Buna karşın *böbrek taşı* sınıfı gibi küçük ve zor tespit edilen yapılar için ortalama AP değeri oldukça düşüktür (0.143). Bu durum, modelin ana hedef sınıfta henüz yeterince genelleşemediğini göstermektedir.

Çıkarım süresi açısından, YOLOv11m ortalama 23.3 milisaniyede bir görüntü işlerken, Faster R-CNN 109.87 milisaniyeye ihtiyaç duymuştur. Bu da yaklaşık olarak YOLOv11m için 43 FPS, Faster R-CNN için ise 9.1 FPS anlamına gelir ve YOLOv11m'nin gerçek zamanlı sistemler için uygunluğunu güçlendirir.

Özetle:

- **YOLOv11m**, düşük kaynaklı veya gerçek zamanlı ortamlar için en uygun seçimdir.
- **Faster R-CNN**, özellikle daha yüksek doğruluk gereken tanı amaçlı kullanımlarda potansiyel taşımaktadır, ancak eğitim süresi ve stratejileri optimize edilmelidir.

TABLE I
YOLOv11M VE FASTER R-CNN PERFORMANS VE KAYNAK
KARŞILAŞTIRMASI

Metik	YOLOv11m	Faster R-CNN
Parametre Sayısı (M)	20.0	41.8
Model Boyutu (MB)	40.5	173.4
Eğitim Epoch Sayısı	60	5
mAP@0.5 (ortalama)	0.789	0.684
mAP@0.5 (böbrek taşı)	0.598	0.143
mAP@0.5 (normal böbrek)	0.979	0.450
mAP@0.5:0.95 (ortalama)	0.45	0.297
Hassasiyet (ortalama)	0.775	0.627*
Geri Çağırma (ortalama)	0.780	0.435
Çıkarım Süresi (ms/görüntü)	23.3	109.87
FPS	43	9.10

V. DENEYLER VE SONUÇLAR

A. DeneySEL Kurulum

Tüm deneyler, böbrek taşı ve normal böbrek olmak üzere iki hedef sınıf içeren aynı ultrason veri kümesi kullanılarak gerçekleştirilmiştir. Kullanılan temel metrikler şunlardır: mAP@0.5, hassasiyet (precision), geri çağırma (recall) ve F1-skoru.

B. Tek Sınıflı ve Çift Sınıflı Deneyler

Sınıf sadeleştirme etkisini değerlendirmek amacıyla, yalnızca **böbrek taşı** sınıfını içeren tek sınıflı bir veri kümesi oluşturulmuştur. YOLOv11 modeli hem tek sınıflı hem de çift sınıflı veri yapılandırılmaları ile eğitilmiş ve aşağıdaki sonuçlar elde edilmiştir:

- Çift sınıf (böbrek taşı): Doğrulama/Test mAP50 yaklaşık %62/%60
- Tek sınıf: Doğrulama mAP50 yaklaşık %63
- Normal böbrek sınıfı: Çift sınıf yapılandırmasında doğrulama mAP50 yaklaşık %98

Bu sonuçlar, sınıf sadeleştirme ana sınıf için yalnızca sınırlı bir iyileşme sağladığını, ancak çift sınıflı modelin daha genel ve çok yönlü olduğunu göstermektedir.

C. YOLOv11 Üzerindeki Ön İşleme Stratejilerinin Etkisi

Farklı ön işleme yaklaşımlarının nesne tespit doğruluğu üzerindeki etkisini değerlendirmek amacıyla, YOLOv11 mimarisi kullanılarak üç ayrı deney gerçekleştirilmiştir. Her deney aynı veri kümesini, etiketleri, hiperparametreleri ve 20




Fig. 7. mAP50 karşılaştırması: çift sınıflı ve tek sınıflı YOLOv11 modelleri.

epoch süresince aynı eğitim yapılandırmasını kullanmıştır. Tek fark, eğitim öncesinde uygulanan ön işleme türüdür:

- **Ön İşleme Yok:** Sadece Ultralytics kütüphanesinin sunduğu varsayılan işlemler uygulanmıştır.
- **Temel Ön İşleme:** Varsayılan işlemlere ek olarak, Medyan Bulanıklaştırma ($k = 5$) ve CLAHE (Sınırlı Kontrast Uyumlu Histogram Eşitleme, parça boyutu = 8×8) uygulanmıştır.
- **Gelişmiş Gürültü Azaltma (BM3D + FFT):** Speckle gürültüsünü daha ileri düzeyde bastırmak amacıyla, Dabov ve arkadaşları [10] tarafından önerilen BM3D algoritması uygulanmıştır.

Tüm deneyler aynı yapılandırmalarla eğitilmiş ve model performansı; eğitim logları ve değerlendirme metrikleri (mAP@0.5, hassasiyet, geri çağırma) ile karşılaştırılmıştır. Sonuçlar Tablo II'da özetlenmiştir.

TABLE II
FARKLI ÖN İŞLEME STRATEJİLERİ ALTINDA YOLOv11 PERFORMANS KARŞILAŞTIRMASI

Metrik	Yok	Temel	Gelişmiş
mAP@0.5 (böbrek taşı)	0.75999	0.75274	0.75111
Precision	0.75026	0.76079	0.77449
Recall	0.73994	0.72786	0.73294
Eğitim Kutu Kaybı	1.84996	1.86336	1.86394
Eğitim Sınıf Kaybı	1.13328	1.16353	1.18476
Eğitim DFL Kaybı	1.42640	1.42017	1.37726

Tablo II'dan da görülebileceği üzere, üç ön işleme stratejisi arasında mAP@0.5, geri çağırma ve eğitim kayıpları açısından benzer performanslar elde edilmiştir. Gelişmiş gürültü azaltma yöntemi precision'da hafif bir artış sağlamış (0.77449), ancak genel mAP değerini artırmamıştır.

Gelişmiş yöntemle elde edilen daha yüksek sınıf kaybı (1.18476), buna karşılık daha düşük DFL (Distribution Focal Loss) değeri, sınırlayıcı kutu konumlandırmalarının daha rafine olduğunu göstermektedir. Bu da gelişmiş denoising yönteminin model güvenliğini ve kutu kalitesini artırdığını, ancak genel tespit başarımında sınırlı etkisi olduğunu göstermektedir.

Bu sonuçlar, YOLOv11'in yerleşik artırma ve normalizasyon boru hattının zaten gürültülü ultrason verilerine karşı oldukça dayanıklı olduğunu göstermektedir. Ek ön işleme adımları—temel veya gelişmiş—yalnızca marjinal

iyileştirmeler sağlayabilir ve gerçek zamanlı uygulamalarda hesaplama yükü göz önünde bulundurularak dikkatli kullanılmalıdır.

D. Uzun Süreli Faster R-CNN Eğitiminde Aşırı Öğrenme (Overfitting)

Model kapasitesi ve eğitim dinamiklerini daha derinlemesine incelemek amacıyla, Faster R-CNN modeli ilk denemede kullanılan 5 epoch yerine bu sefer 20 epoch boyunca eğitilmiştir. Ancak bu uzatılmış eğitim süreci performansı artırmak yerine, özellikle böbrek taşı sınıfında belirgin bir doğruluk düşüşüne yol açmıştır. Bu durum, modelin aşırı öğrenme (overfitting) belirtileri gösterdiğini ortaya koymuştur.

Tablo III, 5 ve 20 epoch sonunda elde edilen performans metriklerini özetlemektedir. Normal böbrek sınıfındaki performans büyük ölçüde stabil kalırken, böbrek taşı sınıfında Ortalama Doğruluk (AP) ve Ortalama Geri Çağırma (AR) değerlerinde açık bir düşüş gözlenmiştir. Genel ortalamalar da uzatılmış eğitimle birlikte gerilemiştir.

TABLE III
FARKLI EPOCH SAYILARINDA FASTER R-CNN PERFORMANS METRİKLERİ

Metrik	5 Epoch	20 Epoch
AP (Böbrek Taşı)	0.142	0.119
AR (Böbrek Taşı)	0.302	0.256
AP (Normal Böbrek)	0.450	0.446
AR (Normal Böbrek)	0.570	0.554
Ortalama AP	0.296	0.282
Ortalama AR	0.436	0.405

Bu sonuçlar, modelin özellikle azınlık sınıf (böbrek taşı) için genel özellikleri öğrenmek yerine, eğitim verisindeki örnekleri ezberlemeye başladığını göstermektedir. Epoch sayısının artırılması, ek düzenleme (regularization) yöntemleri veya sınıf dengesi stratejileri olmadan test zamanı performansında düşüşe neden olmuştur.

E. Düşük Parametrelili Faster R-CNN Modellerinde Öğrenme Karşılaştırması

Aşırı öğrenmeye karşı daha dayanıklı olabilecek, parametre sayısı daha az ve daha hafif backbone'lara sahip Faster R-CNN modellerinin performansı da analiz edilmiştir. Bu amaçla, **MobileNetV3 Large FPN** ve **ResNet18** omurgaları ile eğitilmiş modeller, 5 epoch boyunca eğitilmiş ve değerlendirilmiştir.

Bu bölümde kullanılan karşılaştırmalı metrikler; mAP@0.5 (ortalama doğruluk), sınıf başına ortalama doğruluk (AP), sınıf başına ortalama geri çağırma (AR), küçük nesne başarımı ve genel çıkarım doğruluğu gibi ölçütleri kapsamaktadır.

TABLE IV
DÜŞÜK PARAMETRELİLİ FASTER R-CNN MODELLERİ: 20 EPOCH EĞİTİM SONUÇLARI

Model	Kidney AP	Normal AP	mAP@0.5	AR (avg)
MobileNetV3-FPN	0.062	0.527	0.589	0.378
ResNet18	0.003	0.353	0.448	0.292

Sonuçlar, düşük parametrelili modellerin özellikle küçük nesne (böbrek taşı) sınıfında sınırlı performans gösterdiğini

ortaya koymaktadır. ResNet18 modeli ile elde edilen böbrek taşı AP değeri 0.003 gibi oldukça düşük bir seviyede kalmıştır. MobileNetV3-FPN modeli ise normal böbrek sınıfında yüksek doğruluk sağlasa da, böbrek taşı sınıfında yetersiz kalmıştır.

Bu durum, backbone mimarisinin hem sınıf genellemesi hem de küçük nesne tespit performansı açısından kritik bir rol oynadığını göstermektedir. Özellikle düşük parametrelili modellerin, küçük ve azınlıkta olan nesne sınıflarında başarıyı artırmak için daha ileri veri artırımı, focal loss ya da anchor optimizasyonu gibi stratejilere ihtiyaç duyabileceği düşünülmektedir.

F. Karşılaştırmalı Gözlemler

Yapılan deneysel çalışmalar doğrultusunda elde edilen bulgular aşağıda özetlenmiştir:

- **Faster R-CNN:** Özellikle normal böbrek gibi daha büyük ve belirgin yapılar için yüksek doğruluk göstermiştir. Ancak böbrek taşı gibi küçük ve zorlayıcı yapılar söz konusu olduğunda modelin ortalama AP değeri belirgin şekilde düşmüştür. Bu durum, Faster R-CNN'in hedef sınıflarda yeterince genelleşemediğini ortaya koymaktadır.
- **YOLOv11:** Gerçek zamanlı uygulamalar için yeterli doğruluk sunarken, çok daha hızlı çıkarım süresiyle öne çıkmıştır. Daha düşük kaynak tüketimiyle sahada kullanılabilirlik açısından avantaj sağlamıştır.
- **Ön İşleme:** Gelişmiş gürültü azaltma yöntemi tahmin güvenini artırsa da, genel mAP üzerinde anlamlı bir etki yaratmamıştır. YOLOv11'in yerleşik artırma ve filtreleme mekanizmaları, temel gürültüleri halihazırda yeterince absorbe etmektedir.
- **Sınıf Stratejisi:** Tek sınıflı eğitim, böbrek taşı gibi belirli hedefler için küçük kazançlar sağlasa da, çift sınıflı modeller klinik açıdan daha anlamlıdır; çünkü hem patolojik hem de normal yapıların birlikte tespitini mümkün kılar.

VI. İLGİLİ ÇALIŞMALAR

Böbrek taşı tespiti, tıbbi görüntüleme alanında uzun süredir çalışılan bir konudur ve bu çalışmaların çoğu, yüksek çözünürlük ve anatomik netlik nedeniyle bilgisayarlı tomografi (BT) verilerine odaklanmıştır. Ancak ultrason (USG) görüntülerine dayalı böbrek taşı tespitiyle ilgili çalışmalar görece daha azdır. Bunun temel nedeni, USG görüntülerinin düşük kontrastlı ve yüksek gürültülü olmasıdır. Bu proje, derin öğrenme tabanlı nesne tespiti modelleri geliştirerek bu az çalışılmış alana katkı sağlamaktadır.

A. Geleneksel Yaklaşımlar

Önceki bazı çalışmalar, klasik makine öğrenmesi ve görüntü işleme tekniklerine dayanmıştır:

- Kala ve Gunasundari [2], ultrason görüntülerini seviye seti (level set) yöntemleri ile segmente eden ve ardından yapay sinir ağı (ANN) ile sınıflandırma yapan bir sistem önermiştir. Veri kümesi, gri tonlamalı USG görüntülerden elde segmentlenmiş böbrek bölgeleri içermektedir. Sistem, kontrollü ortamlarda tatmin edici doğruluklar elde

etmiş olsa da, gürültüye olan duyarlılığı ve sınırlı ölçeklenebilirliği klinik uygulanabilirliğini azaltmıştır.

- Shahzad ve arkadaşları [3], mikroskop altında çıkarılmış böbrek taşlarını sınıflandırmak için geometrik ve doku tabanlı özelliklerin birleştirildiği bir yapı önermiştir. %90'ın üzerinde sınıflandırma doğruluğu elde edilmiş olmasına rağmen, bu yaklaşım canlı (in vivo) görüntüler yerine laboratuvar ortamında elde edilen örnekler üzerinde test edilmiştir; bu da gerçek dünya uygulamaları açısından sınırlayıcıdır.

B. BT Görüntüleri Üzerine Derin Öğrenme

Son yıllarda, derin öğrenme modelleri BT görüntüleri üzerinde böbrek taşı tespiti amacıyla yaygın şekilde kullanılmaya başlanmıştır:

- Caglayan ve arkadaşları [4], klinik ortamdan toplanan yüksek çözünürlüklü BT taramaları üzerinde eğitilmiş CNN tabanlı bir model geliştirmiştir. Yüzlerce etiketli tarama içeren veri kümesi ile model %96 doğrulukla böbrek taşlarını tespit ve lokalize etmiştir. BT görüntüleme yüksek netlik sunsa da, maliyeti ve bazı hasta grupları için radyasyon riski nedeniyle tarama amaçlı kullanıma uygun değildir.

C. Ultrason Tabanlı Tespit Çalışmalarındaki Boşluk

Yapay zekânın tıbbi görüntüleme alanındaki kullanımıyla birlikte, ultrason verisi kullanılarak böbrek taşı tespiti yapılan çalışmalar literatürde sınırlıdır. Bu alandaki temel zorluklar arasında lekeli gürültü, kullanıcıya (operatöre) bağımlılık ve sınırlı anatomik detay yer alır.

Bu projede bu boşluk aşağıdaki şekilde ele alınmıştır:

- Roboflow Universe platformundan temin edilen ve "kidney stone" ile "normal kidney" etiketleri içeren açık veri kümesi kullanılmıştır.
- Gerçek dünya gürültüsüne sahip ultrason verisi üzerinde performansı test edilen iki tamamlayıcı nesne tespit mimarisi (Faster R-CNN ve YOLOv11) uygulanmıştır.
- İki sınıflı ve tek sınıflı eğitim senaryoları altında mAP, hassasiyet, geri çağırma ve F1-skoru gibi metriklerle doğruluk ölçümü yapılmıştır.

D. Bu Çalışmanın Literatüre Katkıları

Bu çalışma, mevcut literatürü aşağıdaki yönlerden genişletmektedir:

- Sadece sınıflandırma değil, nesne tespiti yapılmakta ve USG karelerinde böbrek taşlarının konumları hassas şekilde belirlenmektedir.
- YOLOv11'in düşük kaynaklı ve gerçek zamanlı sistemlerdeki uygulanabilirliği detaylı şekilde değerlendirilmiştir.
- Ön işleme ve veri artırımı teknikleri ile ultrasonun sınırlamalarına karşı yapay zekâ sistemlerinin uyum sağlayabileceği gösterilmiştir.
- Dabov ve arkadaşları [10] tarafından tanıtılan Blok Eşleştirme ve 3D filtreleme (BM3D) algoritmasının, speckle ve Gauss gürültüsünü azaltmadaki gücü bu

çalışmada değerlendirilmiş; buna frekans tabanlı brushlet eşikleme eklenerek ultrasona özgü bozulmalar azaltılmıştır.

- Bu çalışma, ileride benzer araştırmalar yapacak araştırmacılar için metodolojik bir rehber niteliğindedir. Okuyucu, gerçekleştirilen deneyler aracılığıyla hangi yaklaşımların etkili olduğunu, hangilerinin sınırlı başarı sağladığını doğrudan gözlemleyebilir. Örneğin; modellerin ultrason görüntülerindeki gürültüyü zamanla "öğrenerek" hatalı genellemeler yapabildiği ya da küçük objelerin (örneğin taşlar) tespitinde performansın sınırlı kaldığı anlaşılmakta; bu da daha ileri düzey gürültü bastırma teknikleri veya küçük nesne tespiti için özelleşmiş mimarilere yönelimin gerekliliğini ortaya koymaktadır.

Sonuç olarak, bu proje yalnızca derin öğrenme ile böbrek taşı tespiti yapılabileceğini doğrulamakla kalmamış; aynı zamanda erişilebilir, taşınabilir ve radyasyon içermeyen tanı araçları için yeni araştırma alanlarının önünü açmıştır.

VII. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışma, ultrason görüntülerinde böbrek taşı tespiti amacıyla iki modern nesne tespiti modeli—Faster R-CNN ve YOLOv11—kullanarak kapsamlı bir derin öğrenme yaklaşımı sunmaktadır. Bu çalışmanın temel motivasyonu, BT görüntülemenin maliyetli, erişimi sınırlı ve radyasyona maruz bırakan yapısına karşı, daha erişilebilir, non-invaziv ve radyasyonsuz tanı araçlarına olan klinik ihtiyaca dayanmaktadır.

Düşük kontrast, yüksek gürültü ve değişken görüntüleme koşulları gibi ultrason görüntülemenin zorluklarına rağmen, her iki model de umut verici sonuçlar vermiştir. YOLOv11, çıkarım hızı ve dağıtım esnekliği ile öne çıkarken; Faster R-CNN belirli senaryolarda daha rafine sınırlayıcı kutular üretmiştir. Ancak küçük nesneleri (böbrek taşları) tespit etme konusunda YOLOv11 genel olarak daha iyi bir performans sergilemiştir.

Uygulama sürecinde çeşitli sınırlamalarla karşılaşmıştır. Google Colab gibi sınırlı donanım kaynaklarında çalışmak, eğitim süresini ve deney derinliğini sınırlamıştır. Etiketleme tutarsızlıkları nedeniyle bazı görüntüler manuel olarak elenmiş; speckle gürültüsü ve düşük kontrast gibi ultrasona özgü sorunlar ise özel gürültü azaltma ve ön işleme stratejileriyle hafifletilmiştir. Ancak bu sınırlamalara rağmen, YOLOv11 gibi yapılar gürültülü yapıları ve tipik ultrason dokularını "öğrenerek" bu görüntülere özgü sinyalleri ayırtmada başarılı olmuştur.

Ayrıca, Faster R-CNN'in bazı durumlarda arka plan-daki ultrason dokusunu yanlışlıkla taş olarak sınıflandırdığı gözlemlenmiştir. Bu da, sınırlı veriyle çalışan modellerin görüntüye gömülü sistematik artefaktları da "öğrenebildiğini" göstermektedir. Bu açıdan bakıldığında, küçük nesnelerin varlığı, speckle yapılarıyla olan benzerliği ve etiket hataları gibi etmenler model başarımı üzerinde önemli rol oynamıştır.

İki sınıflı ve tek sınıflı veri kümesi konfigürasyonları, ön işleme stratejileri ve veri artırımı teknikleri gibi çeşitli deney-

sel senaryolarla yapılan kapsamlı testler sonucunda, modeller sınırlı ve gürültülü tıbbi verilerle etkili şekilde çalışacak şekilde optimize edilmiştir. mAP50, precision, recall ve F1-skoru gibi metriklerle yapılan karşılaştırmalı değerlendirme, her bir mimarinin güçlü ve zayıf yönlerini ortaya koymuştur.

A. Temel Katkılar

- Ultrason görüntülerinde böbrek taşı tespiti için nesne tespit modellerinin uygulanabilirliğini göstermiştir.
- Faster R-CNN ve YOLOv11 mimarilerini destekleyen modüler bir boru hattı geliştirilmiştir.
- Farklı veri kümesi yapılandırmaları ve kaynak kısıtları altında model performansı deneysel olarak doğrulanmıştır.
- Gerçek dünyaya yönelik sorunlar (donanım sınırı, gürültü, yanlış etiketler) çözüm odaklı stratejilerle ele alınmıştır.

B. Gelecek Çalışmalar

Bu projenin üzerine inşa edilebilecek bazı önerilen araştırma ve geliştirme alanları şunlardır:

- **Hiperparametre Ayarlamaları:** Optuna veya Grid Search gibi araçlarla sistematik optimizasyonlar yapılabilir.
- **Daha Büyük ve Uzman Etiketli Veri Setleri:** Klinik kurumlara iş birliği yapılarak uzman etiketli, daha kapsamlı veri setleri oluşturulabilir.
- **Küçük Nesneleri Daha İyi Tespit Eden Mimariler:** Transformer tabanlı ya da dikkat (attention) mekanizmaları içeren daha yeni modeller denenebilir.
- **Kullanıcı Arayüzü Geliştirme:** Kliniklerin kolayca kullanabileceği bir grafiksel arayüz oluşturularak hastane ortamlarında yaygınlaştırılabilir.
- **Klinik Testler:** Hekimlerle birlikte pilot çalışmalar gerçekleştirilerek sistemin tanı doğruluğu ve iş akışına katkısı değerlendirilebilir.

Bu proje, yapay zekânın yalnızca yüksek kaliteli görüntülerle değil; zorlu ve sınırlı ultrason verileriyle de etkili sonuçlar üretebileceğini göstermiştir. Böylece, tıbbi tanının erişilebilirliğini artıran, maliyeti düşüren ve hasta bakım süreçlerini daha erken ve doğru müdahalelerle iyileştiren sistemlerin önünü açmaktadır.

KAYNAKÇA

- [1] Hakan Doğan Proje Kodları, [Online]. Available: Google Drive Linki
- [2] Hakan Doğan Proje Sunumu, [Online]. Available: YouTube Videosu
- [3] V. Kala and R. Gunasundari, "Design and analysis performance of kidney stone detection from ultrasound image by level set segmentation and ANN classification," in *Proceedings of the 2014 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*, pp. 407–414, 2014, doi: 10.1109/ICACCI.2014.6968485.
- [4] K. Shahzad, F. Azam, S. Rehman, A. Alfalou, S. Rubab, and J. A. Khan, "Expelled kidney stones classification using feature fusion," in *Pattern Recognition and Tracking XXXII*, vol. 11735, M. S. Alam, Ed. SPIE, 2021, pp. 117350F. doi: 10.1117/12.2586815.
- [5] A. Caglayan, M. O. Horsanali, K. Kocadurdu, E. Ismailoglu, and S. Guneyli, "Deep learning model-assisted detection of kidney stones on computed tomography," *International Brazilian Journal of Urology*, vol. 48, no. 5, pp. 830–839, Sep-Oct 2022, doi: 10.1590/S1677-5538.IBJU.2022.0132.

- [6] Ultralytics, “YOLOv5 by Ultralytics,” [Online]. Available: <https://github.com/ultralytics/yolov5>
- [7] PyTorch, “Torchvision Object Detection Finetuning Tutorial,” [Online]. Available: https://pytorch.org/tutorials/intermediate/torchvision_tutorial.html
- [8] A. Buslaev et al., “Albumentations: Fast and flexible image augmentations,” *Information*, vol. 11, no. 2, pp. 125, 2020, doi: 10.3390/info11020125.
- [9] F. Chollet, “Deep Learning with Python,” 2nd ed., Manning Publications, 2021.
- [10] Roboflow Universe, “Kidney Stone Ultrasound Dataset (ECCKD),” [Online]. Available: <https://universe.roboflow.com/radiology/kidney-stone-ultrasound-ecckd>
- [11] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian, “BM3D image denoising with shape-adaptive principal component analysis,” in *Proc. Workshop on Signal Processing with Adaptive Sparse Structured Representations (SPARS)*, 2009.

Ek: DEĞERLENDİRME METRİKLERİ AÇIKLAMALARI

Bu çalışmada, nesne tespit modellerinin performansını değerlendirmek için aşağıdaki metrikler kullanılmıştır:

- **mAP (Mean Average Precision):** Tüm sınıflar için ortalama Average Precision (AP) değeridir. Modelin genel tespit doğruluğunu özetler. Bu çalışmada genellikle **mAP@0.5** ve **mAP@0.5:0.95** versiyonları kullanılmıştır.
- **mAP@0.5:** IoU (Intersection over Union) eşiği 0.5 kabul edilerek yapılan AP hesaplamalarının ortalamasıdır. Nesne tespitinde en yaygın kullanılan başarı göstergesidir.
- **mAP@0.5:0.95:** IoU eşiği 0.5’ten 0.95’e kadar (0.05 aralıklarla) değişerek hesaplanan 10 farklı AP değerinin ortalamasıdır. Daha zorlayıcı ve ayrıntılı bir değerlendirme sağlar.
- **AP (Average Precision):** Bir sınıfa ait Precision-Recall eğrisi altındaki alanı temsil eder. Yalnızca o sınıf için model başarısını ölçer.
- **AR (Average Recall):** Belirli bir sınıf için, farklı IoU eşik değerlerinde ortalama geri çağırma oranıdır. Modelin ne kadar kapsayıcı olduğunu ölçer.
- **Precision (Hassasiyet):** Modelin pozitif olarak tahmin ettiği kutuların ne kadarının doğru olduğunu gösterir.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall (Geri Çağırma):** Gerçek nesnelerden kaç tanesinin doğru şekilde tespit edildiğini gösterir.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score:** Precision ve recall değerlerinin harmonik ortalamasıdır. Dengeli bir genel başarı ölçütüdür.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **IoU (Intersection over Union):** Tahmin edilen kutu ile gerçek kutunun örtüşme oranıdır. Değer 1’e yaklaştıkça örtüşme kalitesi artar.

$$\text{IoU} = \frac{\text{Kesişim Alanı}}{\text{Birleşim Alanı}}$$

- **Loss (Kayıp Fonksiyonu):** Modelin tahmin hatasını temsil eder. Bu projede kutu kaybı (Box Loss), sınıf kaybı (Class Loss) ve DFL (Distribution Focal Loss) gibi bileşenlerle takip edilmiştir.